Universidad Don Bosco

Facultada de Ingeniería

Escuela de computación



Asignatura: Data Warehouse y Minería de Datos

Caso de Estudio 3 DMD

Docente: Ing. Karens Medrano

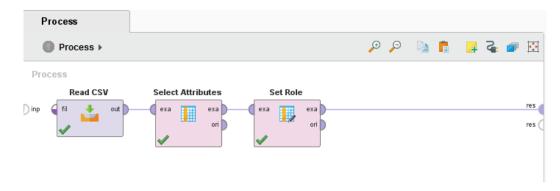
Integrantes:

Apellidos	Nombres	Carnet
Lemus Cardoza	Nelson Orlando	LC111108
López Revelo	Cristian Odir	LR161911
Barriere Campos	Gerson Daniel	BC200025

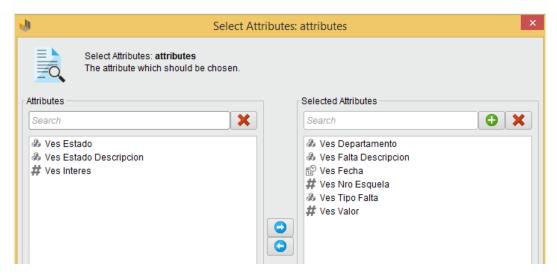
ANALISIS PARA ESQUELAS DE TRANSITO

REGLAS DE ASOCIACIÓN.

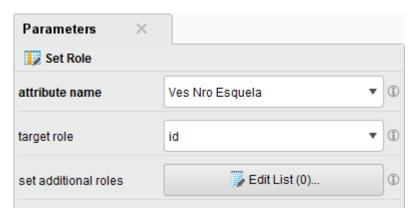
 Para analizar la data de Esquelas para el cierre del año 2018, dispondremos a utilizar la herramienta de RapidMiner. Nos dirigimos abrirla, ya adentro de la aplicación creamos el siguiente diagrama



2. Dentro de las configuraciones para Select Atribute, seleccionaremos solamente las columnas consideradas relevantes para el estudio.



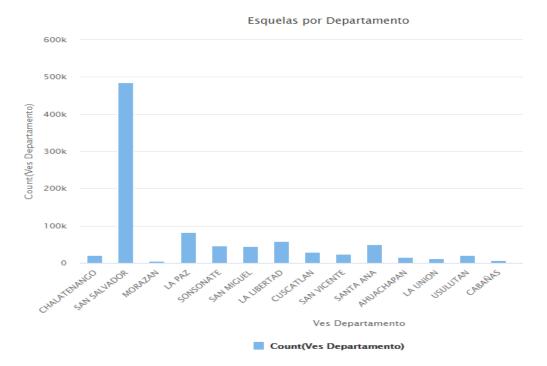
Luego para set Role nos dirigimos a declarar Ves Nro Esquela de tipo id.



3. Procedemos a ejecutar y verificamos si los datos se procesaron correctamente

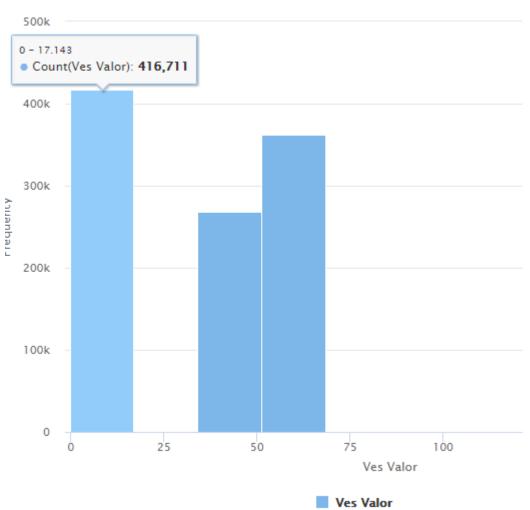
Result History	■ Ex	ampleSet (Set R	ole) ×				
Data	Open in Turbo Prep Auto Model Filter (1,046,999 /					er (1,046,999 / 1,046	
	Row No.	Ves Nro Esq	Ves Fecha	Ves Tipo Falta	Ves Falta De	Ves Departa	Ves Valor
Statistics	1	110637	Jun 4, 2003 1	TRANSITO	NO UTILIZAR	?	34.290
	2	107742	Jun 4, 2003 1	TRANSITO	NO UTILIZAR	CHALATENA	34.290
	3	154061	Jun 4, 2003 1	TRANSITO	BAJAR O SU	SAN SALVAD	34.290
	4	154102	Jun 3, 2003 1	TRANSITO	DISPUTARS	?	57.140
Visualizations	5	119779	Jun 6, 2003 1	TRANSITO	CONDUCIR	?	57.140
	6	106938	Jun 4, 2003 1	TRANSITO	TRANSPORT	SAN SALVAD	57.140
	7	154457	Jun 4, 2003 1	TRANSITO	TRANSPORT	SAN SALVAD	57.140
Simple Charts	8	154951	Jun 6, 2003 1	TRANSPORT	NO RESPET	SAN SALVAD	57.140
	9	154976	Jun 6, 2003 1	TRANSPORT	NO RESPET	SAN SALVAD	57.140
	10	109210	Jun 6, 2003 1	TRANSPORT	EFECTUAR P	?	34.290
Advanced Charts	11	109211	Jun 6, 2003 1	TRANSPORT	EFECTUAR P	SAN SALVAD	34.290
	12	109207	Jun 6, 2003 1	TRANSPORT	EFECTUAR P	?	34.290
	13	105578	Jun 9, 2003 1	TRANSITO	CIRCULAR C	?	11.430
	14	109469	Jun 6, 2003 1	TRANSPORT	EFECTUAR P	SAN SALVAD	34.290

4. Una vez cargado nuestros datos podemos dirigirnos a estadísticas y visualizaciones para poder analizar los datos que se presentan. Como podemos ver dentro de visualizaciones el departamento con más esquelas registradas es San Salvador seguido de La Paz.

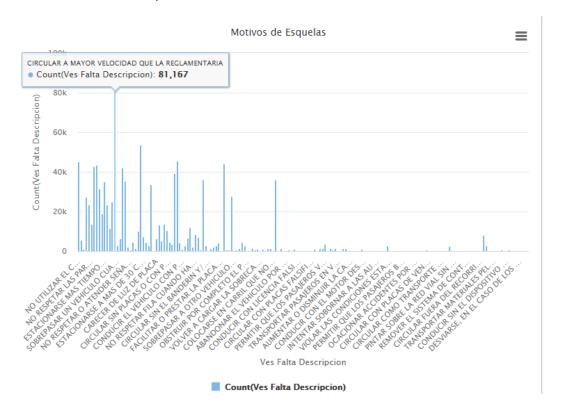


5. En seguida revisaremos cual el monto de la esquela que más asignan los policías y cómo podemos ver la que más se asigna tiene un monto de \$11.43



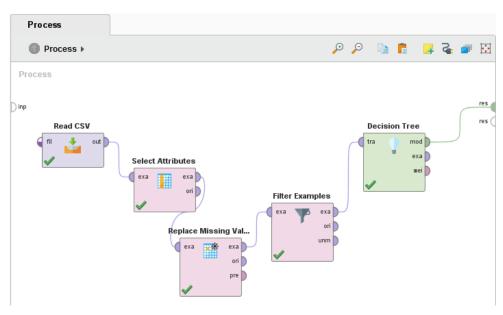


6. Luego nos dirigimos y generamos la gráfica para las descripciones/motivos por los que se asignan las esquelas. Como podemos ver el motivo por el cual se asignan la mayor cantidad de esquelas se debe a la excesiva velocidad.

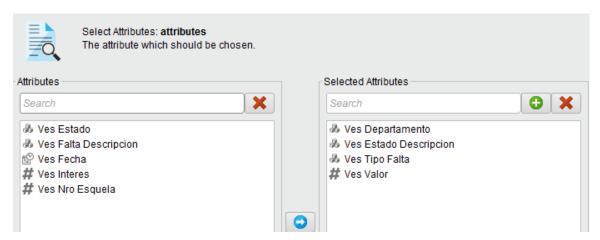


• ARBOL DE DECISIONES.

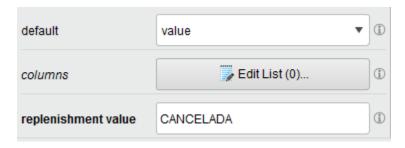
7. Crearemos un nuevo proceso en RapidMiner y procederemos a colocar y conectar los siguientes componentes como se muestra a continuación



8. Dentro de Select Attribute seleccionaremos las columnas que necesitamos para el analisis



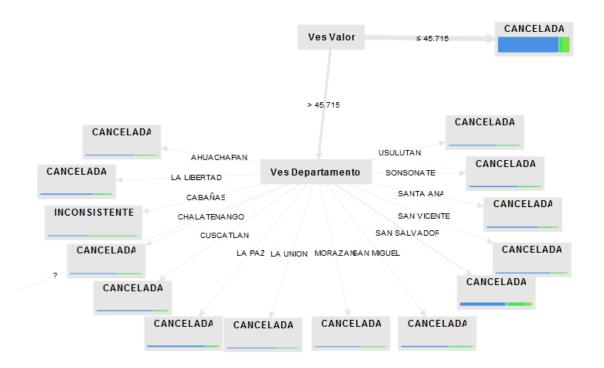
9. Dentro de Replace Missing Values colocaremos CANCELADA, en todos esos espacios que se encuentren vacío dentro de Ves Estado Descripción, esto debido a que esa columna es tomada como etiqueta para el desarrollo del árbol por ende no pueden campos vacíos.



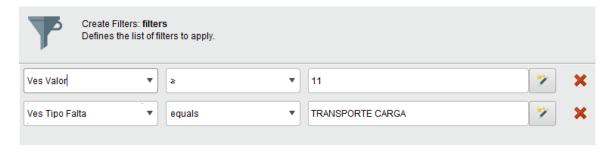
10. Ahora dentro de Filter Examples limitaremos nuestra información a procesar colocando lo siguiente, mostrando solamente el tipo de falta que sean de transito



11. Como podemos ver en nuestro árbol para, el tipo de falta de TRANSITO nos dice que la mayoría de las esquelas que sobrepasan los \$42.715 a nivel nacional tienden hacer más pagadas y para las demás esquelas que corresponden a las de \$11.43 y \$34.19 se encuentran desglosadas por cada departamento siendo la gran mayoría de estas esquelas saldadas.

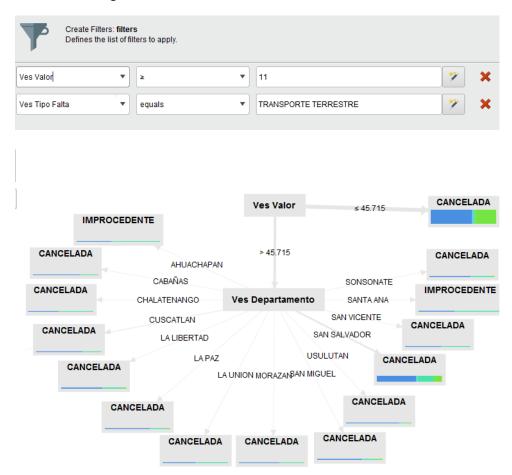


12. Para el tipo de falta de TRANSPORTE DE CARGA, podemos ver que hay más posibilidades que sean pagadas la esquela de \$57.14 más que las otras dos, sin embargo, eso no quiere decir que la gente no pague las anteriores, simplemente tiene una frecuencia de pago menor

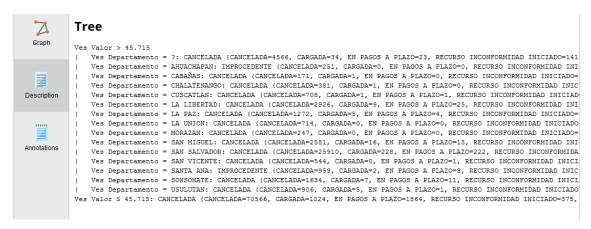




13. Finalmente, para el tipo de falta de TRANSPORTE TERRESTRE, tenemos que la gran mayoría de gente se inclinaría más por pagar las esquelas y no dejarlas como inconsistente o con algún otro inconveniente.



14. También si quisiéramos datos más específicos podemos desglosar los diferentes estados en los que las esquelas se encuentran.



ANALISIS PARA PARQUE VEHICULAR

CREACION DE ETL.

1. Primero creamos las tablas en la base de datos de SQL para generar el diagrama estrella de nuestro análisis. Se debe crear también una tabla auxiliar llamada (DataPVehicular) esta funcionará para el análisis de datos y poder crear las llaves foráneas de unión a la tabla de hechos.

```
Tabla auxiliar para análisis
 create database PVehicular
 go
 use PVehicular
□CREATE TABLE [DataPVehicular] (
     [TIPO PLACA] nvarchar(50),
     [CANTIDAD_DE_CILINDROS] numeric(20,0),
     [CANTIDAD_DE_PUERTAS] numeric(20,0),
     [VALOR_DEL_VEHICULO] decimal(28,0),
     [FECHA_DE_INGRESO] date,
     [ANIO_INGRESO] bigint,
     [MES INGRESO] bigint,
     [CLASE] nvarchar(50),
     [PERTENENCIA] nvarchar(50),
     [MARCA] nvarchar(50),
     [MODELO] nvarchar(50),
     [CAPACIDAD] decimal(28,0)
     [DES_CAPACIDAD] nvarchar(50),
     [COMBUSTIBLE] nvarchar(50),
     [CONDICION_INGRESO] nvarchar(50),
     [PROPIETARIO_DEPARTAMENTO] nvarchar(50),
     [PROPIETARIO_MUNICIPIO] nvarchar(50),
     [ESTADO] nvarchar(50))
```

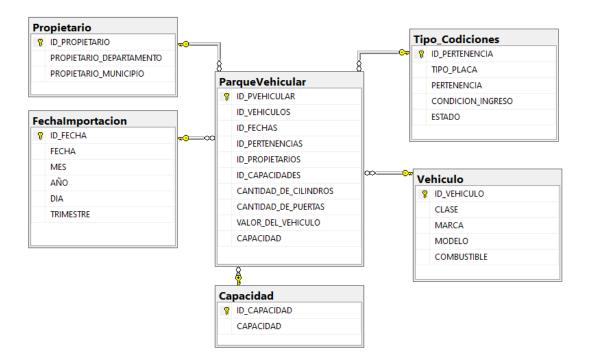
Tablas de Dimensiones

```
CREATE TABLE Vehiculo (
     ID_VEHICULO INT IDENTITY(1,1) PRIMARY KEY,
     CLASE nvarchar(50),
     MARCA nvarchar(50)
     MODELO nvarchar(50),
     COMBUSTIBLE nvarchar(50))
□CREATE TABLE FechaImportacion (
     ID_FECHA INT IDENTITY(1,1) PRIMARY KEY,
     FECHA DATE,
     MES VARCHAR(15),
                                                       □CREATE TABLE Propietario (
     AÑO INT,
                                                            ID PROPIETARIO INT IDENTITY(1,1) PRIMARY KEY,
     DIA INT,
                                                            PROPIETARIO_DEPARTAMENTO nvarchar(50),
     TRIMESTRE INT)
                                                            PROPIETARIO MUNICIPIO nvarchar(50)
□CREATE TABLE Tipo_Codiciones (
     ID_PERTENENCIA INT IDENTITY(1,1) PRIMARY KEY,
                                                       □CREATE TABLE Capacidad (
     TIPO PLACA nvarchar(50),
                                                            ID_CAPACIDAD INT IDENTITY(1,1) PRIMARY KEY,
     PERTENENCIA nvarchar(50),
     CONDICION_INGRESO nvarchar(50),
                                                            CAPACIDAD nvarchar(50))
     ESTADO nvarchar(50))
```

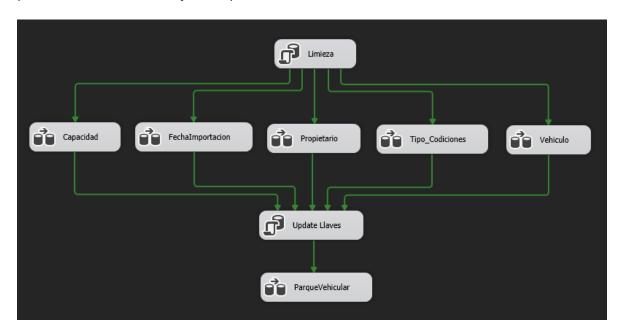
Tabla de Hechos

```
ID_PVEHICULAR INT IDENTITY(1,1) PRIMARY KEY,
    ID_VEHICULOS INT FOREIGN KEY REFERENCES Vehiculo(ID_VEHICULO),
    ID_FECHAS INT FOREIGN KEY REFERENCES FechaImportacion(ID_FECHA),
    ID_PERTENENCIAS INT FOREIGN KEY REFERENCES Tipo_Codiciones(ID_PERTENENCIA),
    ID_PROPIETARIOS INT FOREIGN KEY REFERENCES Propietario(ID_PROPIETARIO),
    ID_CAPACIDADES INT FOREIGN KEY REFERENCES Capacidad(ID_CAPACIDAD),
    CANTIDAD_DE_CILINDROS numeric(20,0),
    CANTIDAD_DE_PUERTAS numeric(20,0),
    VALOR_DEL_VEHICULO decimal(28,0))
GO
```

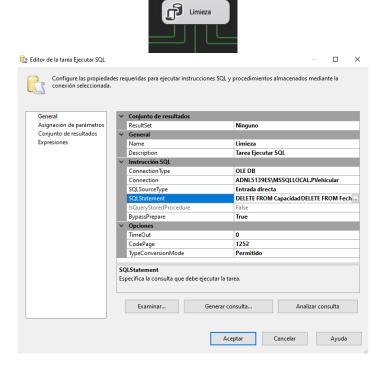
2. El diagrama queda de la siguiente manera. Se logra ver que la tabla de hecho esta unida a las dimensiones formando el diagrama en estrella donde las dimensiones son los atributos de los datos en la tabla hechos.

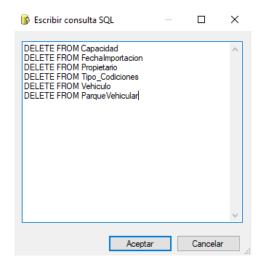


3. Creamos un nuevo proyecto SSIS en visual studio y agregaremos los siguientes componentes a nuestro flujo de control. El orden en que se ejecutan es importante debido las relaciones de llaves foráneas y primarias que existe por lo que primero se ejecuta y llenan los registros para las tablas Capacidad, Fechalmportacion, Propietario, Tipo_Condicion y Vechiulo, luego de procesar las tablas de dimensión continua el flujo actualizando las llaves foráneas para pasar esa información al flujo final que alimentara la tabla de Hechos.



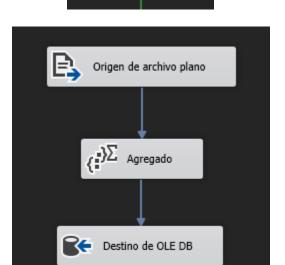
4. Para comprender cada paso del flujo analizamos cada componente, empezamos con el de Limpieza, en este paso nos aseguramos de borrar data que pueda existir en las tablas al momento de pasarle los nuevos datos.



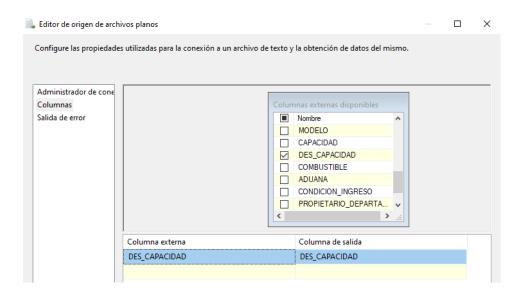


5. Una vez ejecutado el paso de limpieza se irán ejecutando simultáneamente los llenados a las tablas Capacidad, Fechalmportacion, Propietario, Tipo_Condicion y Vechiulo, si analizamos el contenido del flujo capacidad vemos lo siguiente:

Capacidad

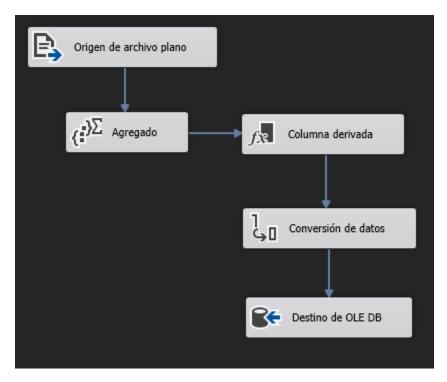


Se debe seleccionar solo el campo DES_CAPACIDAD del origen de datos CSV, luego agrupamos los datos para pasarlos a su destino en la base creada en SQL, como lo vemos en la imagen siguiente:

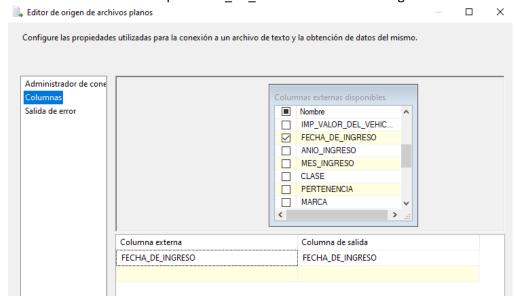


6. Analizando el siguiente flujo de Fechalmportacion, vemos el siguiente esquema.

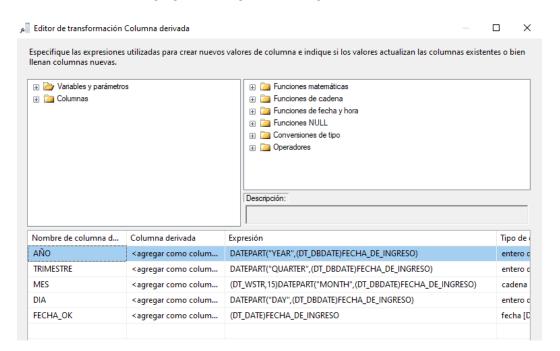




Seleccionamos solo el campo FECHA DE INGRESO del archivo origen CSV



En columna derivada agregamos la siguiente configuración.

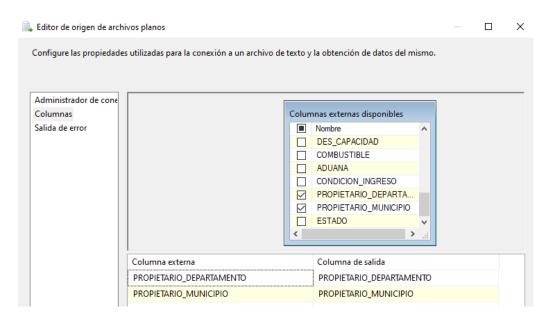


7. Para el flujo Propietario, vemos el siguiente esquema.

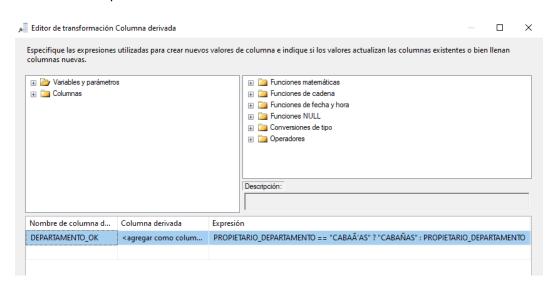




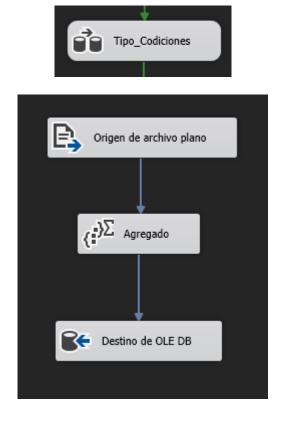
Seleccionamos del origen de datos CSV solo los dos campos que se ven en la imagen.



En la columna derivada agregamos la siguiente configuración, la cual servira para corregir el nombre del departamento de cabañas.



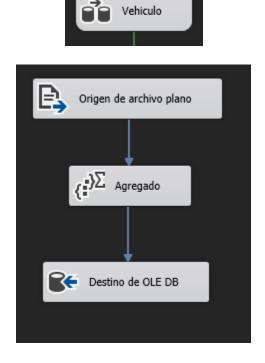
8. Para el flujo de tipo de condiciones, realizamos el esquema siguiente



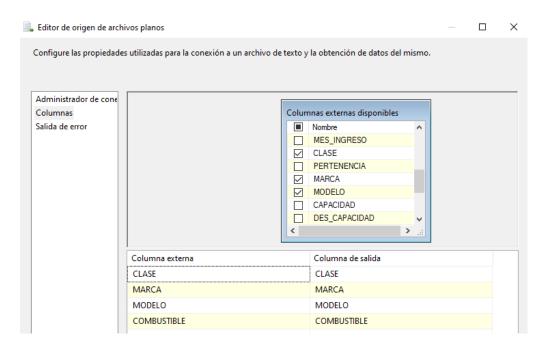
Seleccionamos del origen de datos CSV solo los dos campos que se ven en la imagen.



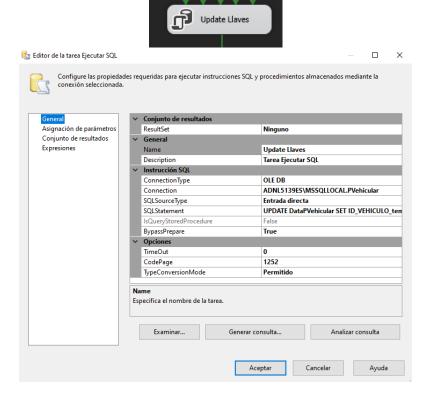
9. Para el flujo de tipo de condiciones, realizamos el esquema siguiente



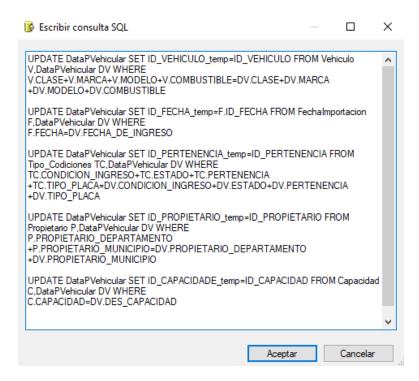
Seleccionamos del origen de datos CSV solo los dos campos que se ven en la imagen.



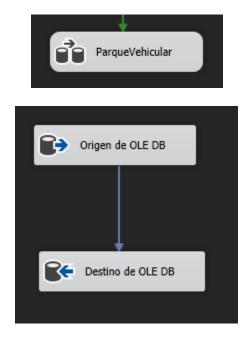
10. Una vez cargadas las tablas de dimensión, pasamos a actualizar la tabla auxiliar con las llaves primarias de cada tabla de dimensión para lograr la conexión entre dimensiones y la tabla de hechos.



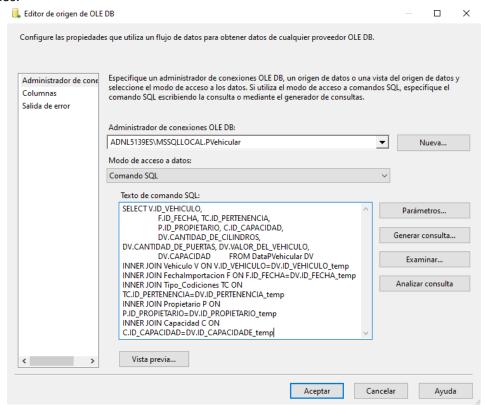
Dentro de este flujo se ejecutaran las siguientes consultas de UPDATE para actualizar las llaves foráneas con la información de las llaves primarias. Son 5 sentencias para pasar las llaves primarias a las llaves foráneas y lograr la conexión.



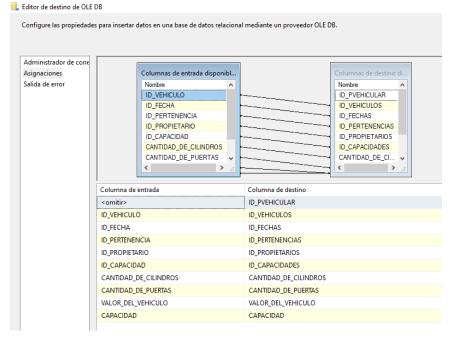
11. Ahora al llegar al flujo final de ParqueVehicular, vemos el siguiente esquema, pero aclarando que en este paso tomaremos la tabla auxiliar DataPVehicular y solo pasaremos los atributos que se definieron en la tabla de hechos junto con las llaves foráneas que se actualizaron en el paso anterior.



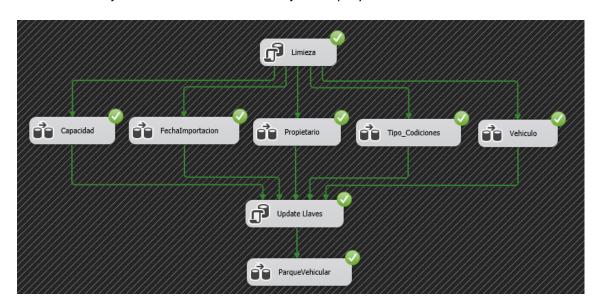
En origen de datos usamos el modo de acceso a datos "Comando SQL" para realizar la extraccion de los campos necesarios mas las llaves foraneas antes de pasarlo a la tabla de hechos.



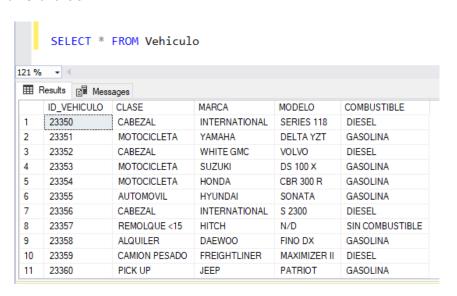
Asignamos las columnas acorde a los campos de la tabla destino dejando el ID_PVEHICULAR sin relacionarlo a la tabla porque esta es la llave primaria de la tabla de hechos.

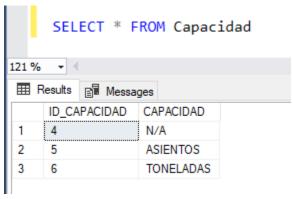


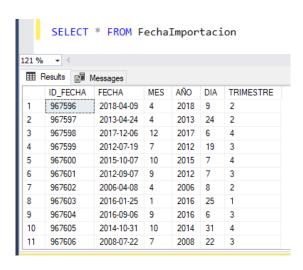
12. Finalmente se ejecuta correctamente cada flujo en el proyecto.



13. Visualizamos que la información se transfirió de forma correcta a las 6 tablas que conforman el análisis.









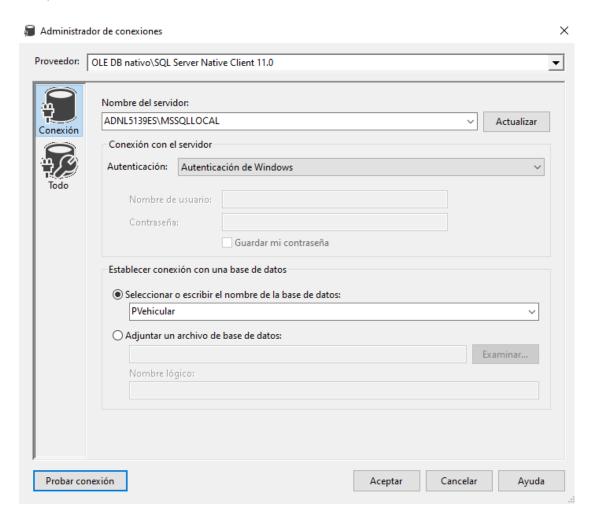
SELECT * FROM Tipo_Codiciones



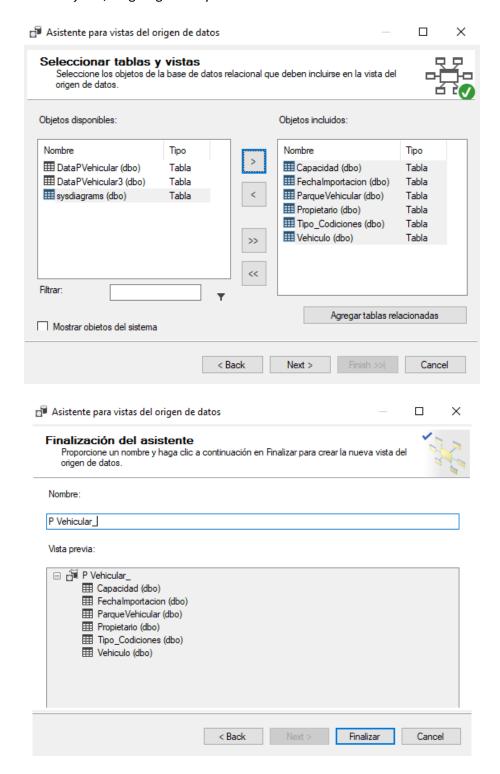


CREACION DE CUBO.

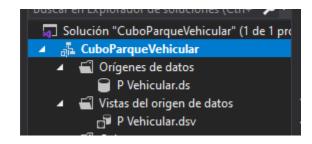
14. Creamos un proyecto nuevo llamada CuboPaqueVehicular. Iniciamos la conexión hacia SQL y seleccionamos la base de datos PVehicular.



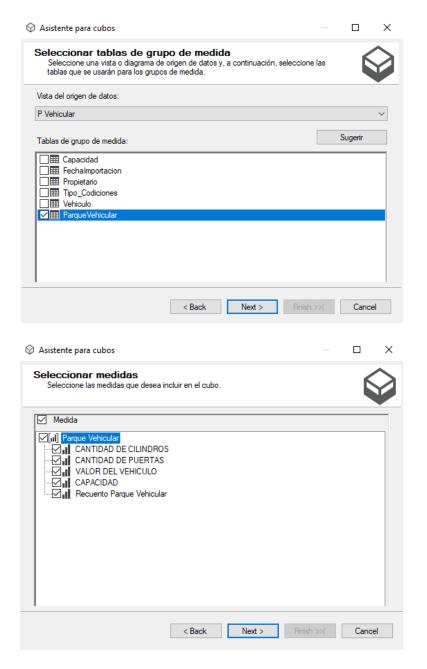
15. Ahora creamos la vistas en la conexión del proyecto, seleccionamos las tablas "Capacidad, Fechalmportacion, ParqueVehicular, Propietario, Tipo_Condiciones, Vehiculo" para incluirlos en Objetos, luego siguiente y finalizamos el asistente



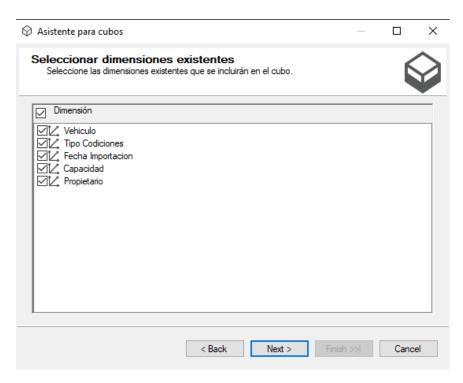
16. Hasta el momento el proyecto queda así:



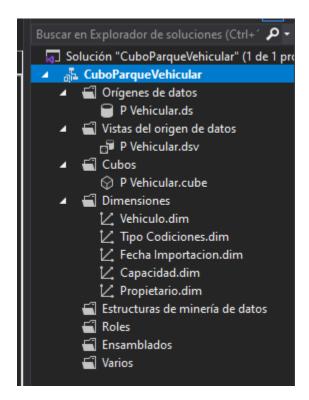
17. Ahora creamos el cubo y seleccionamos la tabla ParqueVehicular como medida ya que contiene los datos para conectar a las demás tablas



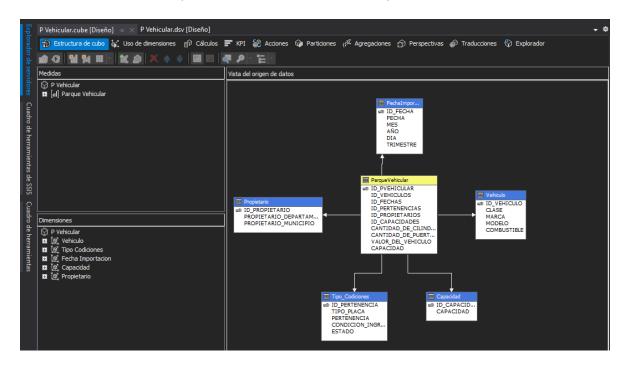
18. Seleccionamos las dimensiones que están conformadas por las tablas Vehiculo, Tipo_Codiciones, Fechalmportacion, Capacidad, Propietario y finalizamos el asistente.



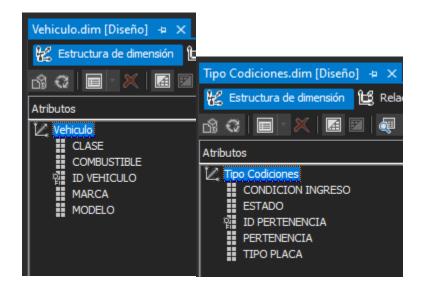
19. El proyecto queda de la siguiente manera:

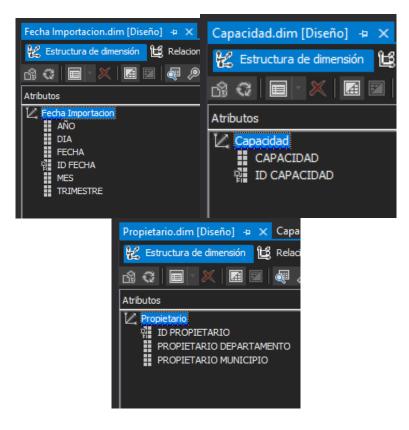


20. Si le damos doble click al cubo creado vemos el diagrama que se crea, es el modelo estrella donde la tabla ParqueVehicular es la tabla de hechos y conecta al resto de tablas

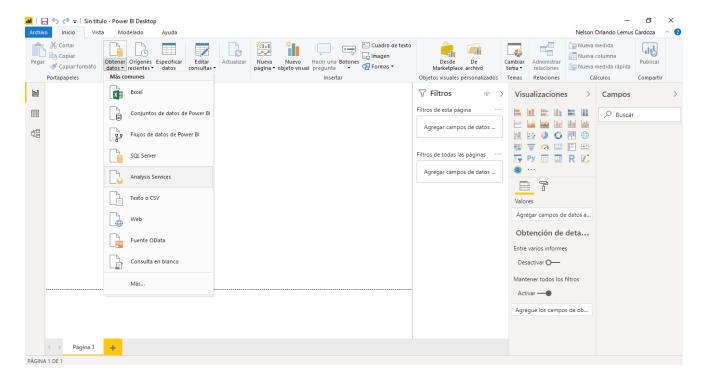


21. Ahora damos doble click a cada dimensión para agregar los atributos con los que exploraremos los datos. Debemos seleccionar todos los atributos de cada dimensión y luego procesar de nuevo el cubo.

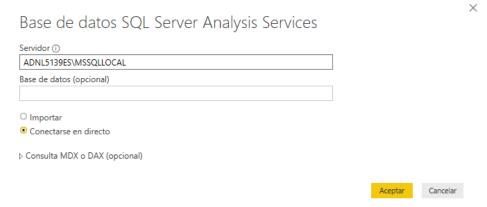




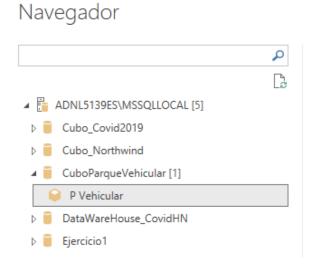
- ANALISANDO DATOS EN POWER BI.
- 22. Analizando la data en PowerBI, damos click en la opción obtener datos y luego en analysis service para conectar a nuestro cubo desde SQL.



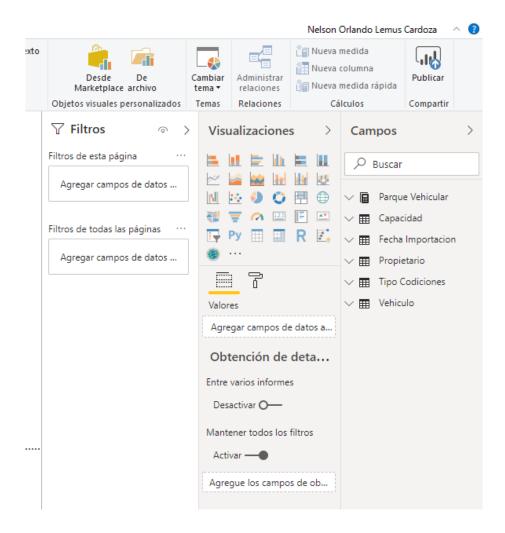
23. Colocamos el nombre de nuestro servidor



24. Luego seleccionamos el cubo PVehicular para establecer la conexión



25. Al realizar la conexión se muestran las medidas y las dimensiones del cubo como objetos seleccionables para analizar la data, también las visualizaciones como tablas, graficas de pastel, barra o lineales



26. En la página 1, agregaremos una grafica de pastel que nos dirá por departamento la participación y el costo de la importación del vehículo.

Agregamos también 1 grafica de líneas que servirá para ver el valor del vehículo importado por año y lograr ver que año de la historia ha sido mas rentable y si continua en crecimiento.

Finalmente agregamos 2 tablas de datos, la primera hará el comparativo de la condición de ingreso (nuevo o usado), el departamento y el costo del vehículo, así podemos analizar mas detallado si un departamento tiene mas vehículos usados o nuevos a su ves podemos comparar dos departamentos y ver cual es el que contenga mas vehículos de cada tipo (usado o nuevo), y la segunda tabla de datos contendrá el top 10 de las marcas con el valor del vehículo mas alto y que nos dé una lectura rápida de que marcas se posicionan mejor por año.

27. Luego vamos a agregar el filtro de departamento y año que filtraran la información que necesitemos en todas la paginas creadas del power BI.

Filtros para todas las páginas.



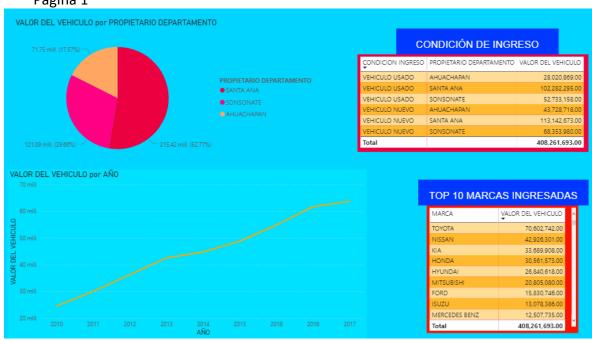
28. En la pagina 2, vamos a agregar 2 graficas de barras donde la primera nos hará el comparativo del valor del vehículo por clase (si es automóvil, moto, autobús, camión, etc) y la segunda grafica nos hará la comparativa del valor del vehículo por placa (si es particular, moto, autobús, camión, etc). Estos datos nos darán una idea rápida que según el periodo del año que se evalué cual es la clase que mas vehículos tiene o cual es la placa que mas vehículos tiene.

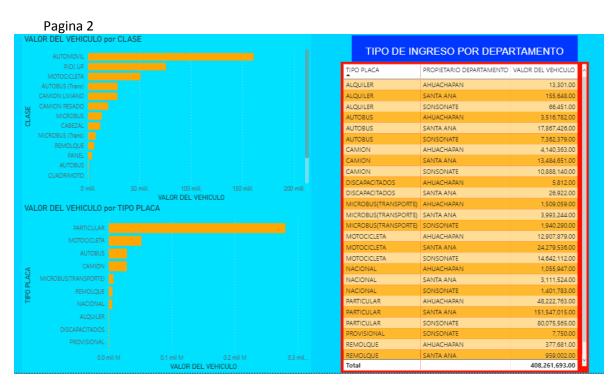
Finalmente agregamos una tabla de datos para poder hacer el comparativo de tipo de placa, departamento y valor de vehículo, así podemos analizar que departamento tiene mayor de saldo y en que tipo de placas específicamente.

La ventaja de que agregamos un filtro de paginas en el paso anterior es que nos permite cambiar el filtro y esto afectara a todas las páginas del documento así que solo basta modificar el filtro 1 vez para analizar ambas hojas y tomar las mejores decisiones del negocio.

Resultados de Datos Comparando año >2010 y Departamentos "Sonsonate, Ahuachapán y Santa Ana".

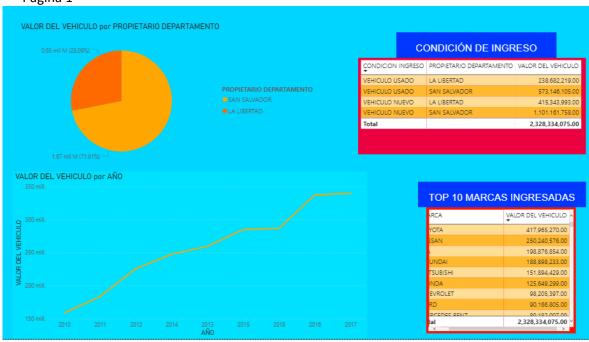






Resultados de Datos Comparando año >2010 y Departamentos "San Salvador, La Libertad".

Pagina 1

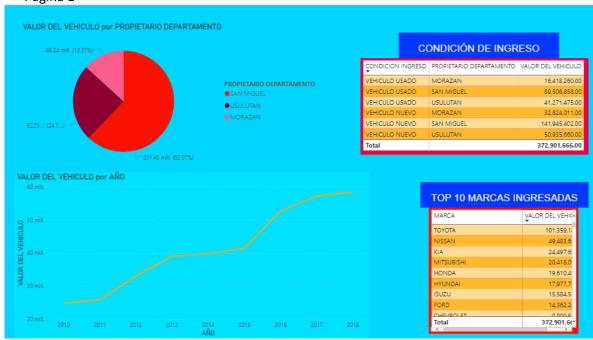






Resultados de Datos Comparando año >2010 y Departamentos "San Miguel, Usulutan y Morazan".

Pagina 1







Resultados de Datos Comparando año 2017 y 2018 y Departamentos "San Salvador, La libertad".

Pagina 1



Pagina 2

